

INFORME FINAL: MODELADO PREDICTIVO CON DATOS ABIERTOS USANDO TECNICAS DE REGRESION Y CLASIFICACION

INFORME FINAL: MODELADO PREDICTIVO CON DATOS ABIERTOS USANDO TECNICAS DE
REGRESION Y CLASIFICACION

Michael Rafael Ventura Bautista

Universidad Autonoma de Santo Domingo

Mineria de Datos | INF-8256-C1

Dr. Edian Franco

21 de marzo de 2026

Resumen

Este informe presenta el análisis comparativo de técnicas predictivas (regresión y clasificación) aplicadas a dos datasets públicos. Se evaluaron cinco algoritmos de machine learning mediante el enfoque CRISP-DM. Los resultados demuestran que los modelos basados en ensambles—particularmente Gradient Boosting Regressor (GBR)—superan significativamente a los modelos lineales, con mejoras del 60-80% en métricas de error. Para clasificación, la Regresión Logística exhibe los mejores indicadores globales (Accuracy: 0.914, AUC: 0.962).

Palabras clave: regresión, clasificación, ensemble methods, Gradient Boosting, predicción energética, desempeño estudiantil.

Metodologia

Se procesaron dos datasets complementarios mediante flujos CRISP-DM completos:

Dataset 1 - Energy Efficiency (Regresión)

- Dimensiones: 768 registros × 10 variables
- Variables predictoras (X1-X8): Compactness, Surface Area, Wall Area, Roof Area, Height, Orientation, Glazing Area, Glazing Distribution
- Targets: Y1 (Heating Load: 6.01-43.1), Y2 (Cooling Load)
- Calidad: Sin valores faltantes, colinealidad moderada entre variables geométricas
- Correlaciones clave: X5-Y1 (0.889), X5-Y2 (0.896)

Dataset 2 - Student Performance (Clasificación)

- Dimensiones: 1,044 registros × 33 variables (fusión datasets português y matemáticas)
- Target binaria: Aprobación ($G3 \geq 10$)
- Correlación clave: G2-G3 (0.910)
- Calidad: Sin nulos, sin valores extremos críticos

Metodologia

Acciones ejecutadas:

- Verificación y tratamiento de valores faltantes
- Detección de outliers mediante boxplots
- Codificación one-hot de variables categóricas (X6, X8, school, sex)
- Escalado de features (StandardScaler) para modelos lineales y regularizados
- Transformación de variables colineales

Algoritmos Comparados

Para ambos análisis se evaluaron cinco algoritmos:

- Linear Regression (referencia)
- Ridge & Lasso (regularización L2/L1)
- Random Forest (RF) - 100 árboles
- Gradient Boosting Regressor/Classifier (GBR) - ensamble secuencial

Análisis de Regresión

Predicción de Heating Load (Y1)

Resultados Comparativos:

Modelo	MAE	RMSE	R ²
Linear Regression	2.059	2.872	0.921
Ridge	2.074	2.885	0.920
Lasso	2.061	2.874	0.921
Random Forest	0.360	0.528	0.997
GBR	0.367	0.503	0.998

Hallazgo principal: GBR y RF superan a modelos lineales en 5-8x en precisión (MAE).

GBR lidera con $R^2 = 0.998$, capturando 99.8% de la varianza. CV RMSE (0.4938 ± 0.0381)

confirma generalización robusta sin sobreajuste.

Importancia de features (GBR): Surface Area domina con 52.9%, seguido de Roof Area (17.8%) y Compactness (9.8%).

Predicción de Cooling Load (Y2)

Resultados Comparativos:

Modelo	MAE	RMSE	R ²
Linear Regression	2.181	3.120	0.895
Ridge	2.185	3.128	0.894
Lasso	2.179	3.121	0.895
Random Forest	1.268	2.036	0.955
GBR	1.079	1.569	0.973

Hallazgo principal: GBR reduce RMSE un 50% respecto a RF y 60% respecto a modelos lineales. Superior desempeño en captura de relaciones no lineales. $R^2 = 0.973$ es excelente para aplicaciones térmicas reales.

Análisis de Clasificación

Predicción de Aprobación Estudiantil

Modelo	Accuracy	Precision	Recall	F1-Score	AUC
Logistic Regression	0.914	0.939	0.951	0.945	0.962
Random Forest	0.900	0.923	0.951	0.937	0.961
GBR	0.904	0.933	0.945	0.939	0.952

Hallazgo principal: Regresión Logística lidera con Accuracy = 0.914 y AUC = 0.962. Su desempeño sugiere buena separabilidad lineal entre clases y menor riesgo de sobreajuste respecto a ensambles basados en árboles.

Distribución de clases: Clase positiva (aprobación) detectada con recall = 0.951 (excelente), precision = 0.939. Clase negativa (desaprobación) con recall = 0.72, indicando conservadurismo relativo.

Conclusiones y Recomendaciones

Para Regresión Energética

Gradient Boosting Regressor es la solución recomendada:

- Reduce RMSE 60-80% vs modelos lineales
- Generalización robusta (CV estable: $\pm 3.8\%$)
- Captura no linealidad compleja en cargas térmicas

- Interpretable mediante importancia de features

Próximos pasos: Optimización de hiperparámetros (learning_rate, max_depth, n_estimators) y deployment en producción.

Para Clasificación de Desempeño

Regresión Logística es la opción operativa:

- Mejor balance generalización-interpretabilidad
- AUC líder (0.962), minimiza falsos positivos críticos
- Menor complejidad computacional que ensambles
- Superior para scoring de riesgo académico

Limitaciones Documentadas

Ambos datasets contienen datos simulados sin mediciones de campo verificadas, lo cual:

- Introduce sesgo en validación cruzada
- Limita extrapolación a contextos reales
- Requiere actualización con data verificada antes de deployment

Recomendaciones Operativas

- Implementar GBR con hiperparámetros sintonizados para cargas energéticas
- Desplegar Logistic Regression para predicción de desempeño estudiantil
- Recolectar datos reales para validación en contextos específicos
- Considerar stacking de modelos si se requiere precision > 0.98 en Y1
- Monitorear drift en producción (cambios en distribuciones)